Tema 2, cursul II, Problema 1. Gaită Marian Gabriel

Timpul de răspuns (ms) al unui model de clasificare, măsurat pe 12 cereri:

88 92 95 97 99 101 104 108 115 126 142 168

1) Calculați media și abaterea standard. Desenați histograma.

$\bar{X} = (88+92+95+97+99+101+104+108+115+126+142+168)/12 = 1335/12 = 111.25$

Abaterea standard.

x	$x-\bar{x}$	$(x-\bar{x})^2$
88	-23,25	540,56
92	-19,25	370,56
95	-16,25	264.06
97	-14,25	203,06
99	-12,25	150,06
101	-10,25	105,06
104	-7,25	52,56
108	-3,25	10,56
115	3,75	14,06
126	14,75	217,56
142	30,75	945,56
168	56,75	3220,56
		6094,25

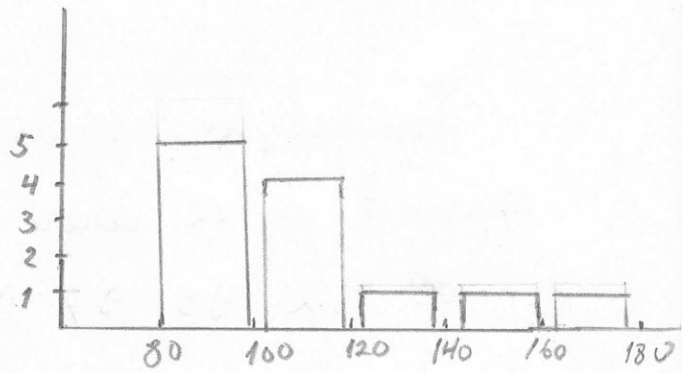
$n-1 = 11$

$s^2 = 6094,25/11 = 554,02$

$s = \sqrt{554,02} = 23.54$ ms

Histograma: - Împart valorile în intervale de 20 ms și număr câte valori intră în fiecare.

Interval	Nr. valori
80 - 100	5
100 - 120	4
120 - 140	1
140 - 160	1
160 - 180	1



2) Testul Lilliefors

D = cea mai mare diferență dintre datele reale și o distribuție normală.

i: - poziția valorii în lista sortată.

$z = (x - 111.25) / 23,54$: la câte abateri standard este x față de medie.

$\varphi(z)$: procentul de valori care ar fi $\leq x$ dacă datele ar fi normale.

i/n : procentul de valori care sunt $\leq x$ în eșantionul obs.

$D^+ = i/n - \varphi(z)$

$D^- = \varphi(z) - (i-1)/n$

Exemplu de calcul ($i = 1$, $x = 88$)

$z = (88 - 111,25) / 23,54 = -23,25 / 23,54 = -0,99$

Din tabel $\varphi(0,99) = 0,8389$, deci $\varphi(-0,99) = 1 - 0,8389 = 0,1611$

$i/n = 1/12 = 0,0833$

$D^+ = 0,0833 - 0,1611 = -0,0778$

$D^- = 0,1611 - 0/12 = 0,1611 - 0 = 0,1611$

i	x	z	$\varphi(z)$	i/n	D^+	D^-
1	88	-0.99	0,1611	0,0833	-0,0778	0,1611
2	92	-0.82	0,2061	0,1667	-0,0394	0,1228
3	95	-0.69	0,2451	0,2500	0,0049	0.0784
4	97	-0.61	0,2709	0,3333	0,0624	0,0209
5	99	-0,52	0,3015	0,4167	0,1152	-0,0318
6	101	-0,44	0,3300	0,5000	0,1700	-0,0867
7	104	-0,31	0,3783	0,5833	0,2050	-0,1217
8	108	-0,14	0,4443	0,6667	0.2224	-0.1390
9	115	0,16	0,5636	0,7500	0,1864	-0,1031
10	126	0,63	0,7357	0,8333	0,0976	-0,0143
11	142	1.31	0,9049	0,9167	0,0118	0,0716
12	168	2.41	0,9920	1,0000	0,0080	0,0753

$D = 0,2224$

La 108 ani, 66,7% din date sunt sub această valoare dar o distribuție normală ar avea doar 44,4%. Datele ~~sunt~~ par tinză o concentrare mai mare a valorilor în zona inferioară a distribuției decât s-ar aștepta în cazul unei distribuții normale.

3) Testul Șapiro-Wilk

Formula $W = b^2 / \sum (x_i - \bar{x})^2$

$$b = \sum_{i=1}^{6} a_i \cdot (x_{13-i} - x_i)$$

i	$13-i$	$x_{13-i} - x_i$	a_i	$a_i \cdot (x_{13-i} - x_i)$
1	12	$x_{12} - x_1 = 168 - 88 = 80$	0,5475	43,800
2	11	$x_{11} - x_2 = 142 - 92 = 50$	0,3325	16,625
3	10	$126 - 95 = 31$	0,2347	7,276
4	9	$115 - 97 = 18$	0,1586	2,855
5	8	$108 - 99 = 9$	0,0922	0,830
6	7	$104 - 101 = 3$	0,0303	0,091

$b = 43,800 + 16,625 + 7,276 + 2,855 + 0,830 + 0,091$
$= 71,476$

$b^2 = 71,476^2 = 5108,82$

$\sum (x_i - \bar{x})^2 = 540,5625 + 370,5625 + 264,0625 + 203,0625$
$+ 150,0625 + 105,0625 + 52,5625 + 10,5625 + 14,0625$
$+ 217,5625 + 945,56,25 + 3220,5625 = 6094,25$

$W = 5108,82 / 6094,25 = 0,838$

$W = 0,838$ este sub W critic de $0,859$ ($\alpha = 0,05$), deci datele pot fi considerate normale.

4) Decideți la $\alpha = 0,05$ cu fiecare test. Ele dorii teste sunt de acord? Explicați.

Ipoteze:
H_0: datele provin dintr-o distribuție normală
H_1: datele nu provin dintr-o distribuție normală

Testul Lilliefors

Regula de decizie: H_0 se respinge dacă $D > D_{critic}$.

$\Delta = 0,222 < \Delta_{critic} = 0,242$

Decizie: nu se respinge H_0. Conform testului Lilliefors, datele pot fi considerate normale.

Testul Shapiro-Wilk

Regula de decizie: H_0 se respinge dacă $W < W_{critic}$. O valoare mai mică a lui W indică o abatere de la normalitate.

$W = 0,838 < W_{critic} = 0,859$

Decizie: se respinge H_0, datele nu sunt normale.

Observație: $W = 0,838 > 0,805$, deci la $\alpha = 0,01$ H_0 nu s-ar respinge. Rezultatul este semnificativ la nivelul de 5%, dar nu la cel de 1%.

Sunt testele de acord?

R: Nu. Cele două teste conduc la concluzii diferite.

Explicație:

Testul Lilliefors se bazează pe o singură valoare, diferența maximă dintre funcția de repartiție empirică și cea normală teoretică. Această diferență apare în zona centrală a datelor (la $x = 108$). Testul este mai puțin sensibil la abaterile din cozile distribuției.

Testul Shapiro-Wilk folosește toate valorile ordonate

, iar cea mai mare pondere o au perechile de la extremități ($a_1 = 0,5475$ pentru perechea 168-88). Din acest motiv detectează asimetria produsă de valorile mari din capătul superior (142 și 168).

Pentru eșantioane mici ($n = 12$), testul Shapiro-Wilk are o putere statistică mai mare, detectând mai ușor abaterile de la normalitate.